

A Beginner's Guide to Linear Models

Seoncheol Park

Seoncheol Park

Contents

Preface	5
I Intro	
1 Introduction	9
1.1 Galton's data	9
II Simple Linear Regression	
2 Simple Linear Regression	13
2.1 Regression analysis	13
2.2 Ordinary least squares (OLS)	13
III Nonlinear and Nonparametric Models	
3 Boosting	17
3.1 Boosting: 개요	17
3.2 AdaBoost	17
3.3 Gradient boosting	17
3.3.1 L^2 boosting	17
3.3.2 Distributional gradient boosting	18
4 커널회귀	19
4.1 RKHS	19
4.2 Kernel Trick	20
4.3 Kernel Trick과 SVM	20
4.3.1 무한차원에서의 kernel trick	21
IV Robust and Quantile Regression	
5 Robust Regression	25
5.1 Robust statistics	25
5.2 Robust Regression	25
6 Quantile Regression	27
6.1 Check loss function	27
6.2 Estimation	27

6.3	Quantile regression as a linear programming	28
6.3.1	R 코드	28
6.4	Quantile crossing	28

V

Linear Model Asymptotics

7	Asymptotic Theory for Least Squares	31
7.1	Consistency of Least Squares Estimator	31
7.2	Asymptotic Normality	32
8	Asymptotic Theory for Quantile Regression	35
8.1	Basics	35

VI

Advanced Topics

9	Spatial Linear Models	39
9.1	Linear Model	39
9.2	Spatial Linear Model	39
9.2.1	Spatial Aitken Model	39
9.3	Spatial General Linear Model	40
10	Gaussian Processes	41
10.1	Regression analysis	41
10.2	Splines vs GP	41
11	PCA and Least Squares	43
11.1	PCA as least squares problems	43
12	Summary	45
	References	47
	Bibliography	49

Preface

열심히 공부합시다.

Seoncheol Park

Seoncheol Park

I

Intro

1	Introduction	9
1.1	Galton's data	9

Seoncheol Park

1 Introduction

- 회귀분석(regression analysis): 설명변수와 반응변수 사이의 함수관계를 알아내는 통계적 방법
- 용어의 역사: Galton의 Regression toward the mean란 말에서부터 유래함

1.1 Galton's data

Q. 아버지와 아들 사이의 키 상관관계?

```
library(HistData)
xx = GaltonFamilies$midparentHeight
yy = GaltonFamilies$childHeight

plot(xx, yy, xlab="Father", ylab="Child", main="Galton's data")
```

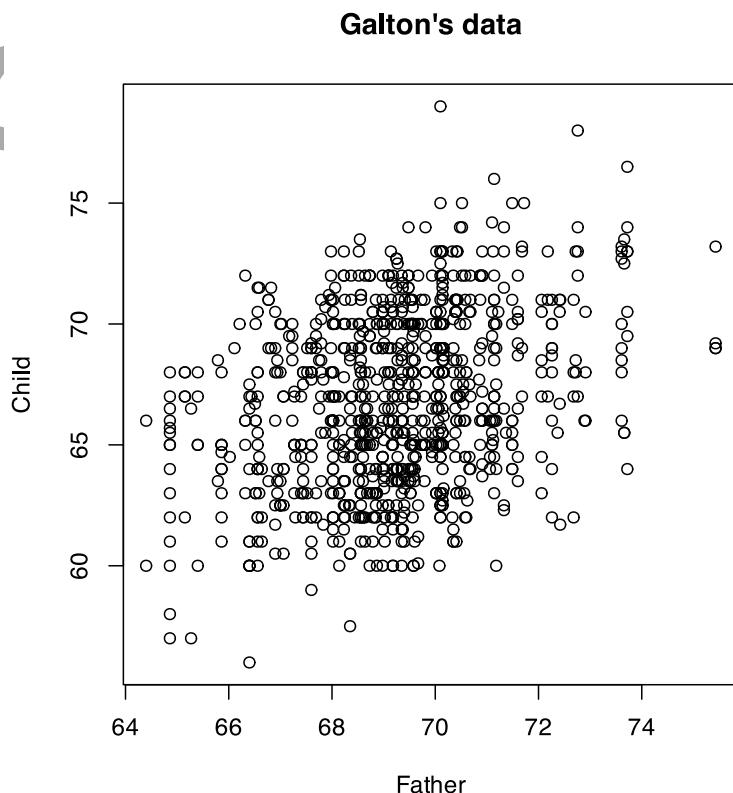


Figure 1.1: Figure: Galton's dataset

Definition 1

테스트 정의이다.

테스트용

Seoncheol Park

II

Simple Linear Regression

2	Simple Linear Regression	13
2.1	Regression analysis	13
2.2	Ordinary least squares (OLS)	13

Seoncheol Park

2 Simple Linear Regression

2.1 Regression analysis

- **Goal:** Find a linear relationship between an explanatory variable (X) and a response variable (Y)

- **Assumptions**

1. Linearity

$$E(Y | X = x) = \beta_0 + \beta_1 x \quad (2.1)$$

2. $Y | x$ follows a normal distribution

3. Constant variance

$$\text{Var}(Y | X = x) = \sigma^2 < \infty \quad (2.2)$$

4. Explanatory variable X is a fixed variable (not random)

5. Response variable Y is a random variable with measurement error $\varepsilon \sim (0, \sigma^2)$

- **Simple linear regression model**

$$y_i = \beta_0 + \beta_1 x_i + \varepsilon_i \quad \text{or} \quad Y = \beta_0 + \beta_1 X + \varepsilon \quad (2.3)$$

2.2 Ordinary least squares (OLS)

With n data points $(x_i, y_i)_{i=1}^n$, our goal is to find the **best** linear fit of the data

$$(x_i, \hat{y}_i = \hat{\beta}_0 + \hat{\beta}_1 x_i)_{i=1}^n \quad (2.4)$$

Q. What is the **best** fit?

Gauss가 제안한 방식은 다음의 **ordinary least squares (OLS)**이다.

$$(\hat{\beta}_0, \hat{\beta}_1) = \arg \min_{\beta_0, \beta_1} \frac{1}{n} \sum_{i=1}^n (y_i - \beta_0 - \beta_1 x_i)^2 \quad (2.5)$$

Exercise 2

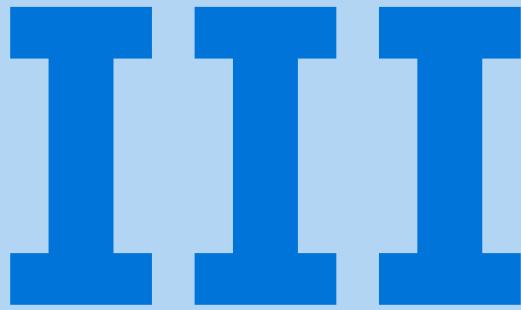
Least absolute deviation (LAD)

Least absolute deviation (LAD)에 대해 조사해보자.

위의 식을 풀기 위해 각각을 β_0, β_1 로 미분 후 0이 되는 $\hat{\beta}_0, \hat{\beta}_1$ 을 찾는 전략을 이용하게 되는데, 여기서 **정규방정식(normal equation)**을 얻게 된다.

$$\begin{cases} -\frac{2}{n} \sum_{i=1}^n (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \\ -\frac{2}{n} \sum_{i=1}^n x_i (y_i - \hat{\beta}_0 - \hat{\beta}_1 x_i) = 0 \end{cases} \quad (2.6)$$

Seoncheol Park



Nonlinear and Nonparametric Models

3	Boosting	17
3.1	Boosting: 개요	17
3.2	AdaBoost	17
3.3	Gradient boosting	17
4	커널회귀	19
4.1	RKHS	19
4.2	Kernel Trick	20
4.3	Kernel Trick과 SVM	20

Seoncheol Park

3 Boosting

3.1 Boosting: 개요

- Boosting의 가장 큰 특징: base learner를 sequentially하게 fitting함
- Base learner로는 weak learner를 사용: tree를 예로 들면 한 번 정도 split한 tree를 base learner로 사용

https://www.uio.no/studier/emner/matnat/math/STK-IN4300/h22/slides/lect10_modified.pdf

3.2 AdaBoost

3.3 Gradient boosting

부스팅 공부할 만한 자료: https://mlcourse.ai/book/topic10/topic10_gradient_boosting.html

3.3.1 L^2 boosting

- Reference: <https://mdporter.github.io/DS6030/lectures/boosting.pdf>

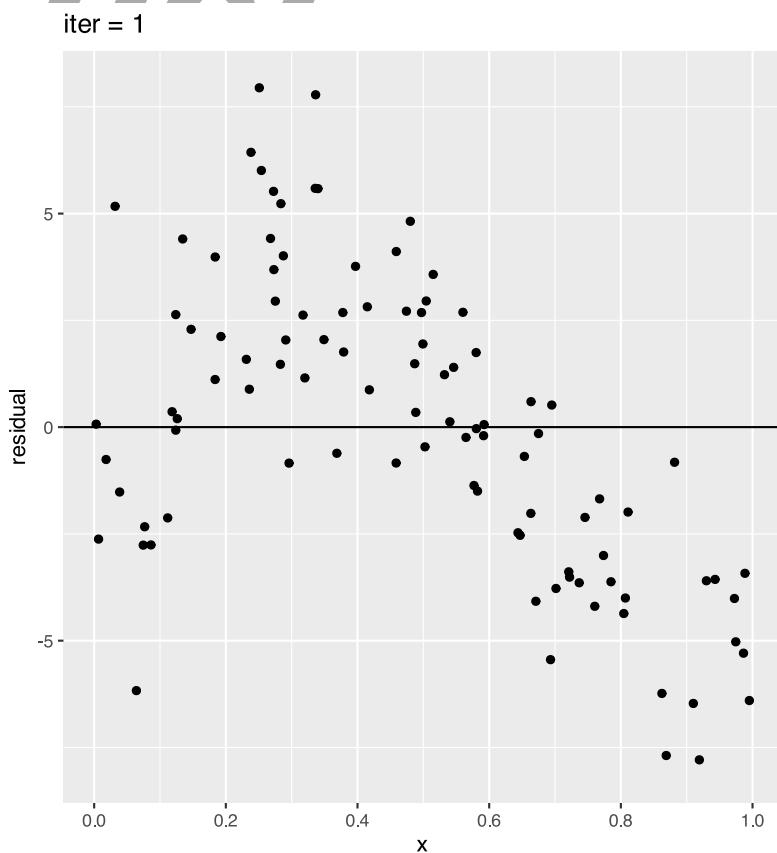


Figure 3.1: L2 boosting

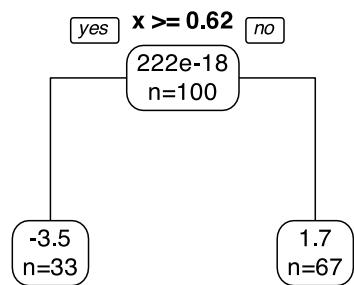


Figure 3.2: L2 boosting

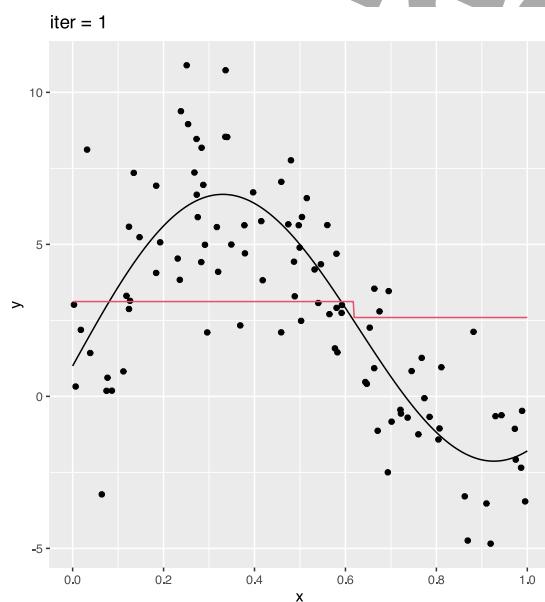


Figure 3.3: L2 boosting

3.3.2 Distributional gradient boosting

- Distributional gradient boosting

4 커널회귀

4.1 RKHS

어떤 $n \times p$ 행렬 A 가 있을 때 이것의 column space를 $C(A)$ 라고 하자.

Ronald Christensen은 아래 $C(XX^T) = C(X)$ 의 결과를 **the fundamental theorem of reproducing kernel Hilbert spaces**라고 부른다.

Definition 3

For any matrix X , $C(XX^T) = C(X)$.

Two column spaces are equiv

Proof. Clearly $C(XX^T) \subset C(X)$, so we need to show that $C(X) \subset C(XX^T)$. Let $x \in C(X)$. Then $x = Xb$ for some b . Write $b = b_0 + b_1$, where $b_0 \in C(X^T)$ and $b_1 \perp C(X^T)$. Clearly, $Xb_1 = 0$, so we have $x = Xb_0$. But $b_0 = X^T d$ for some d ; so $x = Xb_0 = XX^T d$ and $x \in C(XX^T)$.

Definition 4

If $Y = X_1\beta_1 + e_1$ and $Y = X_2\beta_2 + e_2$ are two models for the same dependent variable vector Y , the models are **equivalent** if $C(X_1) = C(X_2)$.

Since $C(X) = C(XX^T)$, this implies that the linear models $Y = X\beta_1 + e_1$ and $Y = XX^T\beta_2 + e_2$ are equivalent.

Equivalent Linear Models

RKHS는 p -벡터 x_i 를 s -벡터 ϕ_i 로 $\phi_i = [\phi_0(x_i), \dots, \phi_{s-1}(x_i)]^T$ 로 변환시킨다. X 를 x_i^T 들이 행으로 구성된 행렬로 보면 똑같은 논리로 ϕ_i^T 가 행으로 구성된 행렬 Φ 를 생각할 수 있다. $X^X = [x_i^T x_j]$ 를 x_i 들의 inner products로 만드는 $n \times n$ 행렬로 보면 RKHS는 **reproducing kernel** $R(\cdot, \cdot)$ 이 존재해

$$\tilde{R} \equiv [R(x_i, x_j)] = [\phi_i^T D(\eta) \phi_j] = \Phi D(\eta) \Phi^T \quad (4.1)$$

가 ϕ_i 들의 $n \times n$ inner product matrix이며 $D(\eta)$ 가 positive definite diagonal matrix가 됨을 말해준다. $D(\eta)$ 가 positive definite diagonal matrix이므로 PA책 Theorem B.22에 의해 $D(\eta) = QQ^T$ 인 정방행렬 Q 가 존재할 것이고 the fundamental theorem of reproducing kernel Hilbert spaces에 따라 s 가 유한하면 $C[\Phi D(\eta) \Phi^T] = C(\Phi)$ 일 것이다. 따라서 rk 모형

$$Y = \tilde{R}\gamma + e \quad (4.2)$$

를 적합하는 것은 다음의 비모수모형

$$Y = \Phi\beta + e \quad (4.3)$$

를 적합하는 것과 같다. 즉 rk 모형은 $\beta = D(\eta)\Phi^T\gamma$ 로 reparametrization한 것이다. 특별히 rk 모형을 이요해 예측하는 것은 다음과 같이 하면 된다.

$$\hat{y}(x) = [R(x, x_1), \dots, R(x, x_n)]\hat{\gamma}. \quad (4.4)$$

Φ 를 가지고 linear structure를 적합하는 것이나 $n \times n$ 행렬 \tilde{R} 을 이용해 적합하는 것이나 같을 것이고 이를 **kernel trick**이라 한다.

Theorem 5

Hilbert space가 RKHS가 되기 위한 조건

A Hilbert space is a RKHS iff the evaluation functionals are continuous.

4.2 Kernel Trick

Kernel trick의 가장 큰 장점은 알려진 함수 $R(\cdot, \cdot)$ 을 쓰므로 \tilde{R} 을 만들어내기 쉽다는 것이다. 반대로 $\phi_j(\cdot)$ 함수들에서 s 를 specify하는 것은 시간이 더 걸릴 것이다.

또한 $n \times s$ 행렬 Φ 는 s 가 크면 이상해지는데, \tilde{R} 은 항상 $n \times n$ 이 되어 s 가 너무 커질 때 이상해지거나 s 가 너무 작을 때 단순화되는 것을 막아준다.

$s \geq n$ 이고 x_i 들이 distinct (같은 값을 갖는 x 들이 없다는 뜻)라면 \tilde{R} 은 $n \times n$ 이고 rank n 인 행렬이며 이것은 saturated model (데이터 수 만큼 모수가 있는 모형)을 만든다. LS estimate는 fitted value가 obs 와 같은 자료를 만들 것이며 d.f는 0이 될 것이다. 즉 overfitting이 있는 것인데, 그래서 보통 kernel trick은 penalized (regularized) estimation과 같이 사용하게 된다.

$s \geq n$ 일 때에는 다른 $R(\cdot, \cdot)$ 을 선택한다 하더라도, 같은 $C(\tilde{R})$ 을 주어 같은 모형을 주는 셈이 된다. 즉 같은 least squares fits를 준다. 그러나 parametrization을 다르게 하고 거기에 penalty를 주는 방식 (ridge, LASSO 등)으로 다른 fitted value를 만들어낼 수 있다.

사용하려고 하는 ϕ_j 함수들을 다 알고 있을 경우, rk를 쓰는 이득이 있다. 그러나 ϕ_j 를 다루기 어렵거나 $s = \infty$ 일 경우에는 rks가 도움이 될 것이다.

다음은 많이 쓰이는 rks들을 정리해 놓았다. $\|u - v\|$ 에만 의존하는 rk들을 **radial basis function** rk라고 부른다.

Names	$R(u, v)$
Polynomial of degree d	$(1 + u^T v)^d$
Polynomial of degree d	$b(c + u^T v)^d$
Gaussian (radial basis)	$\exp(-b \ u - v\ ^2)$
Sigmoid (hyperbolic tangent)	$\tanh(bu^T v + c)$
Linear spline (u, v scalars)	$\min(u, v)$
Cubic spline (u, v scalars)	$\max(u, v) \min^2(u, v)/2 - \min^3(u, v)/6$
Thin plate spline (2 dimensions)	$\ u - v\ ^2 \log(\ u - v\)$

표에 있는 것들 중 hyperbolic tangent는 \tilde{R} 을 not nonnegatively definite한 것들로 줄 수도 있어 실제로 rk는 아니다. 그러나 u 에 대해서 연속인 어떤 $R(u, v)$ 든지

$$f(x) = \sum_{j=1}^n \gamma_j R(x, x_j) \quad (4.5)$$

와 같은 형태의 모형 적합을 유도해낼 수 있기 때문에 이러한 것들을 쓰는 것도 설득력이 있다.

Rk의 아이디어는 함수를 small support를 이용해 근사하는 방법들, 즉 1차원에서 s_* 개의 집합으로 나누고 line의 partition을 만들어내는 wavelet, B-spline 등의 방법과 비교할 수 있다. 이러한 방법들은 당연히 p 차원에서 s_*^p 개의 dimension을 생각해야 하고 고차원에서 다루기 어렵게 된다. 그러나 kernel method에서는 각 data point에 커널을 적합하는 셈이므로 p 가 크게 커져도 괜찮다.

4.3 Kernel Trick과 SVM

함수 안에 dot product가 있으면 kernel trick을 쓸 수 있다고 한다. 이러한 것들 중 대표적인 것이 SVM이다. SVM의 objective function은 다음과 같다.

$$\max_{\alpha} \sum_i \alpha_i - \frac{1}{2} \sum_i \sum_j \alpha_i \alpha_j y_i y_j \mathbf{x}_i^T \mathbf{x}_j, \quad \text{s.t. } \sum_i \alpha_i y_i = 0. \quad (4.6)$$

이 objective 함수 안에는 dot product $\mathbf{x}_i^T \mathbf{x}_j$ 가 들어 있고 kernel trick을 쓸 수 있어 SVM이 강력해진다.

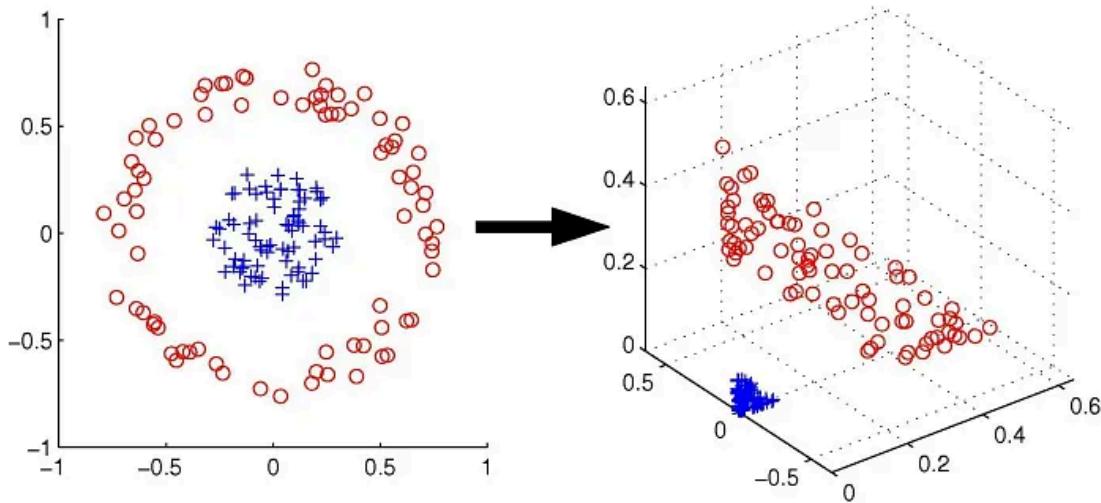


Figure 4.1: Figure: Example of a labeled data inseparable in 2-Dim is separable in 3-Dim.

위 그림에서, 원래 자료 $x = \{x_1, x_2\}$ 는 2차원에 있는데 이것은 inseparable 하지만 변환

$$\Phi(x) \rightarrow (x_1^2, x_2^2, \sqrt{2}x_1x_2) \quad (4.7)$$

를 이용해 오른쪽 그림과 같이 바꾸면 분리가능하다.

앞선 Φ 변환을 이용했을 때 3D 공간에서 decision boundary는 다음과 같다.

$$\beta_0 + \beta_1 x_1^2 + \beta_2 x_2^2 + \beta_3 \sqrt{2}x_1x_2 = 0. \quad (4.8)$$

만약 로지스틱과 같은 회귀를 이용한다면 위의 식과 같은 모형을 쓸 것이다. 그러나 SVM에서는 kernel trick을 이용해 decision boundary를 만들 수 있다. 이를 위해 $\langle \Phi(x_i), \Phi(x_j) \rangle$ 의 dot product를 찾아야 한다.

일단 이것을 하려면

- Φ 를 정의해야 하고
- Φ 변환 계산시 3×2 의 계산
- 그리고 dot product를 계산하는 데 3번 해서

총 9번의 계산이 필요하다. 그러나 만약 커널 $K(x_i, x_j) = \langle x_i, x_j \rangle^2$ 을 이용한다면, 변환 Φ 를 찾을 필요도 없고, 그냥 2차원 공간에서 바로 고차원의 similarity measure (dot product)를 만들어낼 수 있다.
로 만들어낼 수 있다. 이것을 하려면

- K 는 정의해야 하나
- 두 번째 식까지 두 번의 operation
- 마지막 식에서 제곱을 위해 한 번의 operation

3번의 계산이 필요하다.

다른 예제를 보자. Decision boundary를 다음과 같이 정하였다.

$$\beta_0 + \beta_1 x_1 + \beta_2 x_2 + \beta_3 x_1^2 + \beta_4 x_2^2 + \beta_5 \sqrt{2}x_1x_2 = 0. \quad (4.9)$$

$\Phi(x) \rightarrow (1, \sqrt{2}x_1, \sqrt{2}x_2, x_1^2, x_2^2, \sqrt{2}x_1x_2)$ 와 같이 5차원 변환 Φ 를 이용해 구하는 방법은 총 16번의 계산을 필요로 한다.

그러나 커널 $K(x_i, x_j) = \langle 1 + \langle x_i, x_j \rangle \rangle^2$ 를 이용하면 세 번의 계산으로 된다고 한다.

4.3.1 무한차원에서의 kernel trick

앞선 논리를 그대로 적용하면, kernel trick은 infinite space에서도 유사도를 챙 수 있게 해준다. Gaussian Kernel (RBF), exponential kernel, Laplace kernel 등이 실제로 그러한 역할을 한다. Gaussian kernel은 다음과 같다.

$$K(\mathbf{x}_i, \mathbf{x}_j) = \exp\left(-\frac{\|\mathbf{x}_i - \mathbf{x}_j\|^2}{2\sigma^2}\right) \quad (4.10)$$

$\sigma = 1$ 로 두면 위의 Gaussian kernel은 $C = \exp\left(-\frac{1}{2} \|\mathbf{x}_i\|^2\right) \exp\left(-\frac{1}{2} \|\mathbf{x}_j\|^2\right)$ 으로 두었을 때

$$\exp\left(-\frac{1}{2} \|\mathbf{x}_i - \mathbf{x}_j\|^2\right) = C \left\{ 1 - \underbrace{\frac{\langle \mathbf{x}_i, \mathbf{x}_j \rangle}{1!}}_{\text{1st order}} + \underbrace{\frac{\langle \mathbf{x}_i, \mathbf{x}_j \rangle^2}{2!}}_{\text{2nd order}} - \underbrace{\frac{\langle \mathbf{x}_i, \mathbf{x}_j \rangle^3}{3!}}_{\text{3rd order}} + \dots \right\} \quad (4.11)$$

이러한 표현은 무한차원으로 확장 가능하며, Gaussian kernel이 무한차원에서의 유사도를 찾을 수 있게 해 준다.

물론 커널 기반 방법도 커널을 먼저 정해줘야 하며, cross-validation 등을 이용해 커널 함수를 정하거나 또는 커널에 쓰이는 조율모수를 정하게 된다.

Seoncheol Park

IV

Robust and Quantile Regression

5	Robust Regression	25
5.1	Robust statistics	25
5.2	Robust Regression	25
6	Quantile Regression	27
6.1	Check loss function	27
6.2	Estimation	27
6.3	Quantile regression as a linear programming	28
6.4	Quantile crossing	28

Seoncheol Park

5 Robust Regression

5.1 Robust statistics

Q. F 가 오염이 되었을 때 우리가 생각하는 추정량 $\hat{\theta}$ 가 얼마나 영향을 받을 것인가?

- Contaminated distribution function:

$$F_\varepsilon = \varepsilon \delta_y + (1 - \varepsilon)F \quad (5.1)$$

where

– δ_y : mass 1 to the point y

– F : a distribution function

- Influence function of $\hat{\theta}$ at F :

$$IF_{\hat{\theta}}(y, F) = \lim_{\varepsilon \rightarrow 0} \frac{\hat{\theta}(F_\varepsilon) - \hat{\theta}(F)}{\varepsilon} \quad (5.2)$$

5.2 Robust Regression

- Robust regression: 잡음성이 많은 자료에 사용

Seoncheol Park

6 Quantile Regression

6.1 Check loss function

- Check loss function

$$\rho_\tau(u) = u(\tau - I(u < 0)) \quad (6.1)$$

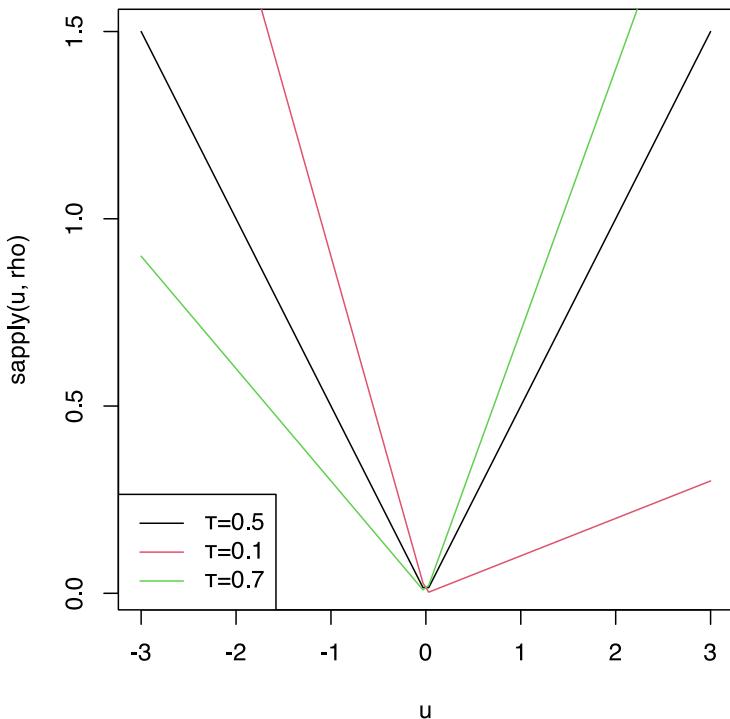


Figure 6.1: Figure: Check loss function.

- Loss function: 값이 클수록 손실이 많음
 - $\tau < 0.5$: $\rho_\tau(u)$ 는 $u < 0$ 일 때 큰 가중치
 - $\tau > 0.5$: $\rho_\tau(u)$ 는 $u > 0$ 일 때 큰 가중치
- $\rho_\tau(u)$ 는 $u = 0$ 에서 미분 불가능

6.2 Estimation

- Objective function

$$R(\beta) = \sum_{i=1}^n \rho_\tau(y_i - x_i^T \beta) = \sum_{i=1}^n \{ \tau | \varepsilon_i | I[\varepsilon_i \geq 0] + (1 - \tau) | \varepsilon_i | I[\varepsilon_i < 0] \} \quad (6.2)$$

- Directional derivative of R in direction w :

$$\begin{aligned}\nabla R(\beta, w) &= \frac{d}{dt} R(\beta + tw) \mid_{t=0} \\ &= \frac{d}{dt}\end{aligned}\tag{6.3}$$

6.3 Quantile regression as a linear programming

- Linear program: solving

$$\min_{\mathbf{z}} \mathbf{c}^T \mathbf{z} \quad \text{subject to } A\mathbf{z} = \mathbf{b}, \mathbf{z} \geq 0 \tag{6.4}$$

- 선형계획 문제를 풀 때는 \mathbf{z} 부분에 해당하는 값이 양수여야 함. 따라서 분위수 회귀문제를 선형계획으로 풀려면 다음과 같이 ε_i 를 slack variable을 이용해 양수와 음수 파트로 나눠야 함.

$$\varepsilon_i = u_i - v_i \tag{6.5}$$

이때

$$\begin{aligned}- u_i &= \max(0, \varepsilon_i) = |\varepsilon_i| I[\varepsilon_i \geq 0] \\ - v_i &= \max(0, -\varepsilon_i) = |\varepsilon_i| I[\varepsilon_i < 0]\end{aligned}$$

- Then

$$\sum_{i=1}^n \rho_\tau(\varepsilon_i) = \sum_{i=1}^n \tau u_i + (1-\tau)v_i = \tau \mathbf{1}_n^T \mathbf{u} + (1-\tau) \mathbf{1}_n^T \mathbf{v} \tag{6.6}$$

여기에서 $\mathbf{u} = (u_1, \dots, u_n)^T$, $\mathbf{v} = (v_1, \dots, v_n)^T$ 이다.

- Quantile regression objective function (Equation (6.2)) may be reformulated as a linear program:

$$\min_{\beta, \mathbf{u}, \mathbf{v}} \{\tau \mathbf{1}_n^T \mathbf{u} + (1-\tau) \mathbf{1}_n^T \mathbf{v} \mid \mathbf{y} = \mathbf{X}\beta + \mathbf{u} - \mathbf{v}\} \tag{6.7}$$

- 알고리즘
 - Simplex method
 - Frisch-Newton interior point method
 - Sparse regression quantile fitting

6.3.1 R 코드

- 출처: [stackexchange](#)

6.4 Quantile crossing

- 분위수 회귀는 기본적으로 각 τ 에 대해 따로 회귀모형을 적합하는 방식이기 때문에 낮은 τ 에서의 조건부 분위수 추정값이 높은 τ 에서의 조건부 분위수 추정값보다 높은 역전 현상이 발생할 수도 있는데, 이를 **quantile crossing**이라 함
- Quantile crossing을 막으려면 한 번에 conditional distribution 전체를 모델링 해야 하고, GAMLSS 등이 그런 방법을 취하고 있으나, 분포가정을 해야 함

V

Linear Model Asymptotics

7	Asymptotic Theory for Least Squares	31
7.1	Consistency of Least Squares Estimator	31
7.2	Asymptotic Normality	32
8	Asymptotic Theory for Quantile Regression	35
8.1	Basics	35

Seoncheol Park

7 Asymptotic Theory for Least Squares

기본적인 내용은 [B. Hansen \[1\]](#) 를 따른다.

Theorem 6

Random sampling assumption

The variables (Y_i, X_i) are a **random sample** if they are mutually independent and identically distributed (i.i.d.) across $i = 1, \dots, n$.

Theorem 7

Best linear predictor 관련 assumption

1. $E[Y^2] < \infty$
2. $E \|X\| < \infty$
3. $Q_{XX} = E[XX^T]$ is positive definite

이 가정의 처음 두 개는 X, Y 가 유한한 평균과 분산, 공분산을 갖음을 의미한다. 세 번째는 Q_{XX} 의 column들이 linearly independent하고 역행렬이 존재함을 보장한다.
(Q_{XX} 가 positive definite일 때 linearly independence는 찾아볼 것)

위의 random sampling과 finite second moment assumption을 가져간채로 least squares estimation에 대한 assumption을 다시 정리한다. ([B. Hansen \[1\]](#) Assumption 7.1)

1. The variables $(Y_i, X_i), i = 1, \dots, n$ are i.i.d.
2. $E[Y^2] < \infty$.
3. $E \|X\| < \infty$.
4. $Q_{XX} = E[XX^T]$ is positive definite.

7.1 Consistency of Least Squares Estimator

이 절의 목표는 $\hat{\beta}$ 가 β 에 consistent함을

1. weak law of large numbers (WLLN)
2. continuous mapping theorem (CMT)

을 이용해 보이는 것이다. ([B. Hansen \[1\]](#) 7.2)

Derivation을 다음과 같은 요소들로 구성된다.

1. OLS estimator가 sample moment들의 집합의 연속함수로 표현될 수 있다.
2. WLLN을 이용해 sample moments가 population moments에 converge in probability함을 보인다.
3. CMT를 이용해 연속함수에서 converges in probability가 보존됨을 보장한다

그렇다면 먼저 OLS estimator를 다음과 같이 sample moments $\hat{Q}_{XX} = \frac{1}{n} \sum_{i=1}^n X_i X_i^T$ 와 $\hat{Q}_{XY} = \frac{1}{n} \sum_{i=1}^n X_i Y_i$ 의 함수로 쓸 수 있다.

$$\hat{\beta} = \left(\frac{1}{n} \sum_{i=1}^n X_i X_i^T \right)^{-1} \left(\frac{1}{n} \sum_{i=1}^n X_i Y_i \right) = \hat{Q}_{XX}^{-1} \hat{Q}_{XY} \quad (7.1)$$

(Y_i, X_i) 가 mutually i.i.d.라는 가정은 (Y_i, X_i) 로 구성된, 예를 들면 $X_i X_i^T$ 와 $X_i Y_i$ 가 i.i.d.임을 의미한다. 이들은 또한 앞선 Assumption 7.1에 의해 finite expectation을 갖는다. 이러한 조건 하에서, $n \rightarrow \infty$ 일 때 WLLN은

$$\hat{Q}_{XX} = \frac{1}{n} \sum_{i=1}^n X_i X_i^T \xrightarrow{P} E[XX^T] = Q_{XX}, \quad \hat{Q}_{XY} = \frac{1}{n} \sum_{i=1}^n X_i Y_i \xrightarrow{P} E[XY] = Q_{XY}. \quad (7.2)$$

그 다음 continuous mapping theorem을 써서 $\hat{\beta} \rightarrow \beta$ 임을 보일 수 있다는 것이다. $n \rightarrow \infty$ 일 때,

$$\hat{\beta} = \hat{Q}_{XX}^{-1} \hat{Q}_{XY} \xrightarrow{P} Q_{XX}^{-1} Q_{XY} = \beta. \quad (7.3)$$

Stochastic order notation으로 다음과 같이 쓸 수 있다.

$$\hat{\beta} = \beta + o_p(1). \quad (7.4)$$

7.2 Asymptotic Normality

Asymptotic normality를 다룰 때에는

1. 먼저 estimator를 sample moment의 함수로 쓰는 것으로부터 시작한다.
2. 그리고 그것들 중 하나가 zero-mean random vector의 sum으로 표현될 수 있고 이는 CLT를 적용 가능케 한다.

우선 $\hat{\beta} - \beta = \hat{Q}_{XX}^{-1} \hat{Q}_{Xe}$ 라고 두자. 그리고 이를 \sqrt{n} 에 곱하면 다음 표현을 얻을 수 있다.

$$\sqrt{n}(\hat{\beta} - \beta) = \left(\frac{1}{n} \sum_{i=1}^n X_i X_i^T \right)^{-1} \left(\frac{1}{\sqrt{n}} \sum_{i=1}^n X_i e_i \right). \quad (7.5)$$

즉 normalized and centered estimator $\sqrt{n}(\hat{\beta} - \beta)$ 은 (1) sample average의 함수 $\left(\frac{1}{n} \sum_{i=1}^n X_i X_i^T \right)^{-1}$ 과 normalized sample average $\left(\frac{1}{\sqrt{n}} \sum_{i=1}^n X_i e_i \right)$ 의 곱으로 쓸 수 있다.

그러면 뒷부분은 $E[Xe] = 0$ 이고 이것의 $k \times k$ 공분산함수를 다음과 같이 둘 수 있다.

$$\Omega = E[(Xe)(Xe)^T] = E[XX^T e^2]. \quad (7.6)$$

그리고 아래 가정에서처럼 $\Omega < \infty$ 라는 가정 하에 $X_i e_i$ 는 i.i.d. mean zero, 유한한 분산을 갖고 CLT에 의해

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n X_i e_i \xrightarrow{d} \mathcal{N}(0, \Omega). \quad (7.7)$$

(B. Hansen [1] Assumption 7.2)

1. The variables $(Y_i, X_i), i = 1, \dots, n$ are i.i.d.
2. $E[Y^4] < \infty$.
3. $E \|X\| < \infty$.
4. $Q_{XX} = E[XX^T]$ is positive definite.

여기서 두 번째 조건이 $\Omega < \infty$ 임을 의미한다. $\Omega < \infty$ 임을 보이려면 j, l 번째 원소 $E[X_j X_l e^2]$ 이 유한함을 보이면 될 것이다. Properties of Linear Projection Model (B. Hansen [1] Theorem 2.9.6) ($If E | Y |^r < \infty$ and $E | X |^r < \infty$ for $r \geq 2$, then $E | e |^r < \infty$)을 이용해 위의 2, 3번 조건에 의해 $E[e^4] < \infty$ 임을 보일 수 있다. 그러면 expectation inequality에 의해 Ω 의 j, l 번째 원소는 다음과 같이 bounded된다.

$$|E[X_j X_l e^2]| \leq E |X_j X_l e^2| = E[|X_j| |X_l| e^2]. \quad (7.8)$$

Cauchy-Schwarz 부등식을 적용하면 다음과 같다.

$$(E[X_j^2 X_l^2])^{1/2} (E[e^4])^{1/2} \leq (E[X_j^4])^{1/4} (E[X_l^4])^{1/4} (E[e^4])^{1/2} < \infty. \quad (7.9)$$

Theorem 8

앞선 가정은

$$\Omega < \infty \quad (7.10)$$

를 내포하고

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n X_i e_i \xrightarrow{d} \mathcal{N}(0, \Omega) \quad (7.11)$$

as $n \rightarrow \infty$.

식 Equation (7.2), Equation (7.5), Equation (7.11) 을 함께 쓰면 다음과 같다.

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} \mathbf{Q}_{XX}^{-1} \mathcal{N}(0, \Omega) = \mathcal{N}(0, \mathbf{Q}_{XX}^{-1} \Omega \mathbf{Q}_{XX}^{-1}) \quad \text{as } n \rightarrow \infty. \quad (7.12)$$

여기서 마지막 등식은 normal vector의 linear combination이 normal이라는 것에서부터 왔다.

Theorem 9**Asymptotic normality of least squares estimator**

앞선 가정 하에서, $n \rightarrow \infty$ 일 때

$$\sqrt{n}(\hat{\beta} - \beta) \xrightarrow{d} \mathcal{N}(0, \mathbf{V}_\beta) \quad (7.13)$$

where $\mathbf{Q}_{XX} = E[XX^T]$, $\Omega = E[XX^T e^2]$, and

$$\mathbf{V}_\beta = \mathbf{Q}_{XX}^{-1} \Omega \mathbf{Q}_{XX}^{-1}. \quad (7.14)$$

Stochastic order notation으로 다음과 같이 쓸 수 있다.

$$\hat{\beta} = \beta + O_p(n^{-1/2}). \quad (7.15)$$

이는 식 Equation (7.4) 보다 더 강한 조건이라고 한다.

Remark

- 원래 o_p 가 더 강한 조건이긴 하나 order의 차이가 나서 저렇게 말하는 듯

- \mathbf{V}_β : **asymptotic covariance matrix** of $\hat{\beta}$,

$$\mathbf{V}_\beta = \mathbf{Q}_{XX}^{-1} \Omega \mathbf{Q}_{XX}^{-1} \quad (7.16)$$

이며 $\sqrt{n}(\hat{\beta} - \beta)$ 의 asymptotic distribution의 variance

Remark

- \mathbf{V}_β 의 형태를 보면 Ω 가 \mathbf{Q}_{XX}^{-1} 사이에 끼어있는 형태이므로 **sandwich form**이라고 부름

Seoncheol Park

8 Asymptotic Theory for Quantile Regression

8.1 Basics

Check function

$$\rho_\tau(x) = x(\tau - I\{x < 0\}) = \begin{cases} -x(1-\tau), & x < 0 \\ x\tau, & x \geq 0 \end{cases} \quad (8.1)$$

$$\psi_\tau(x) = \frac{d}{dx}\rho_\tau(x) = \tau - I\{x < 0\}, \quad x \neq 0. \quad (8.2)$$

Theorem 10

Assume that (Y_i, X_i) are i.i.d., $E |Y| < \infty$, $E[\|X\|^2] < \infty$, $f_\tau(e | x)$ exists and satisfies $f_\tau(e | x) \leq D < \infty$, and the parameter space for β is compact. For any $\tau \in (0, 1)$ such that

$$Q_\tau \stackrel{\text{def}}{=} E[XX^T f_\tau(0 | X)] > 0 \quad (8.3)$$

then $\hat{\beta}_\tau \xrightarrow{p} \beta_\tau$ as $n \rightarrow \infty$.

Theorem 11

Asymptotic distribution of quantile regression estimator

In addition to the assumptions of Theorem 10, assume that $f_\tau(e | x)$ is continuous in e , and β_τ is in the interior of the parameter space. Then as $n \rightarrow \infty$

$$\sqrt{n}(\hat{\beta}_\tau - \beta_\tau) \xrightarrow{d} \mathcal{N}(0, V_\tau) \quad (8.4)$$

where $V_\tau = Q_\tau^{-1} \Omega_\tau Q_\tau^{-1}$ and $Q_\tau = E[XX^T \psi_\tau^2]$ for $\psi_\tau = \tau - I\{Y < X^T \beta_\tau\}$.

Seoncheol Park

VI

Advanced Topics

9	Spatial Linear Models	39
9.1	Linear Model	39
9.2	Spatial Linear Model	39
9.3	Spatial General Linear Model	40
10	Gaussian Processes	41
10.1	Regression analysis	41
10.2	Splines vs GP	41
11	PCA and Least Squares	43
11.1	PCA as least squares problems	43
12	Summary	45
12	References	47
12	Bibliography	49

Seoncheol Park

9 Spatial Linear Models

- Reference: [Spatial Linear Models for Environmental Data](#)

9.1 Linear Model

- A **linear model** for a response variable Y postulates that the response is related to the observed values of p explanatory variables X_1, \dots, X_p via this equation:

$$Y = X_1\beta_1 + X_2\beta_2 + \dots + X_p\beta_p + e, \quad (9.1)$$

where

- β_1, \dots, β_p : (unknown) parameters (**coefficients**)
- e : a random variable (**error**)
- $X_1\beta_1 + X_2\beta_2 + \dots + X_p\beta_p$: mean structure
- When n obs $(y_1, x_1), \dots, (y_n, x_n)$ are taken on the response and explanatory variables, the linear model as just defined implied that

$$y_i = x_i^T \beta + e_i, \quad (i = 1, \dots, n) \quad (9.2)$$

where

- $\beta = (\beta_1, \dots, \beta_p)^T$ and e_1, \dots, e_n are n possibly correlated random variables.
- Using vector and matrix notations:

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{e}. \quad (9.3)$$

- \mathbf{e} : **error vector**
- Σ : $\text{Var}(\mathbf{e})$

9.2 Spatial Linear Model

- A **spatial linear model** is defined as a linear model for spatial data for which the elements of Σ are spatially structured functions of the data sites

9.2.1 Spatial Aitken Model

- The simplest spatial linear model is an extension of the Gauss-Markov model that we call the **spatial Aitken model**:

$$\Sigma = \sigma^2 \mathbf{R}, \quad (9.4)$$

where

- σ^2 : an unknown positive parameter and
- \mathbf{R} is a **known** positive definite matrix whose elements are spatially structured functions of the data sites. We refer to \mathbf{R} as the **scale-free covariance matrix** of the observations; in some settings, but not all, it is a correlation matrix.
- Estimation: **generalized least squares (GLS)**

Example 12**A toy example of a spatial Aitken model**

Consider four obs located at the corners of the unit square in \mathbb{R}^2 , ordered such that the first and last obs are located at opposite corners of the square. Suppose that the model for the obs is given by

$$\mathbf{R} = \begin{pmatrix} 1 & e^{-1} & e^{-1} & e^{-\sqrt{2}} \\ e^{-1} & 1 & e^{-\sqrt{2}} & e^{-1} \\ e^{-1} & e^{-\sqrt{2}} & 1 & e^{-1} \\ e^{-\sqrt{2}} & e^{-1} & e^{-1} & 1 \end{pmatrix} \quad (9.5)$$

- **Symmetric**
- **Positive definiteness:** the variance of any linear combinations of obs having this cov matrix, expect the trivial linear combination with all coeffs equal to zero.

9.3 Spatial General Linear Model

- A more flexible spatial linear model
- Σ is not fully specified but is given by a **known** spatially structured, matrix-valued parametric function $\Sigma(\theta)$, where θ is an **unknown** parameter vector.
- Joint parameter space for β and θ generally taken to be

$$\{(\beta, \theta) : \beta \in \mathbb{R}^p, \theta \in \Theta \subset \mathbb{R}^m\} \quad (9.6)$$

where

- Θ : the set of vectors θ for which $\Sigma(\theta)$ is symmetric and positive definite, or possibly some subset of that set.

Remark 9.1. A spatial Aitken model is a special case of a spatial general linear model, with $\theta \equiv \sigma^2$ and \mathbf{R} not functionally dependent on any unknown parameters.

Example 13**A toy example of a spatial Aitken model (2)**

$$\Sigma(\theta) = \sigma^2 \begin{pmatrix} 1 & e^{-1/\alpha} & e^{-1/\alpha} & e^{-\sqrt{2}/\alpha} \\ e^{-1/\alpha} & 1 & e^{-\sqrt{2}/\alpha} & e^{-1/\alpha} \\ e^{-1/\alpha} & e^{-\sqrt{2}/\alpha} & 1 & e^{-1/\alpha} \\ e^{-\sqrt{2}/\alpha} & e^{-1/\alpha} & e^{-1/\alpha} & 1 \end{pmatrix} \quad (9.7)$$

The parameter space for $\theta \equiv (\sigma^2, \alpha)^T$ within which $\Sigma(\theta)$ is p.d. is

$$\{(\sigma^2, \alpha) : \sigma^2 > 0, \alpha > 0\} \quad (9.8)$$

Small values of α correspond to weak spatial correlation among the obs, and as α increases the spatial correlation among obs become stronger.

10 Gaussian Processes

10.1 Regression analysis

- All finite collection of realizations (n obs) is modeled as having a multivariate normal (MVN) distribution.
- **Mean function:** $\mu(x)$
- **Covariance function:** $\Sigma(x, x')$
- $\Sigma(x, x') = \exp\left\{-\|x - x'\|^2\right\}$
- $\Sigma(x, x) = 1$
- $\Sigma(x, x')$ must be **positive definite**
- Σ_n : covariance matrix (p.d.)

10.2 Splines vs GP

Seoncheol Park

11 PCA and Least Squares

11.1 PCA as least squares problems

PCA can be formulated as follows:

Given m vectors $\mathbf{x}_1, \dots, \mathbf{x}_m \in \mathbb{R}^n$, find matrices $\mathbf{U} \in \mathcal{M}_{\mathbb{R}}(k, n)$ and $\mathbf{V} \in \mathcal{M}_{\mathbb{R}}(n, k)$ such that

$$\sum_{i=1}^m \| \mathbf{x}_i - \mathbf{V}\mathbf{U}\mathbf{x}_i \|^2 \quad (11.1)$$

is minimized.

That is, for $k < n$, the vector $\mathbf{U}\mathbf{x}_i \in \mathbb{R}^k$ is the projection of \mathbf{x}_i into a lower-dimensional subspace, and $\mathbf{V}\mathbf{U}\mathbf{x}_i$ is the **reconstructed** original vector. PCA aims to find matrices \mathbf{U}, \mathbf{V} that minimize the reconstruction error as measured by the ℓ^2 -norm. It can be shown that, in fact, these matrices are orthogonal and $\mathbf{U} = \mathbf{V}^T$, so the problem reduces to

$$\arg \min_{\mathbf{V} \in \mathcal{M}_{\mathbb{R}}(n, k)} \sum_{i=1}^m \| \mathbf{x}_i - \mathbf{V}\mathbf{V}^T\mathbf{x}_i \|^2 \quad (11.2)$$

Further manipulations show that \mathbf{V} is the matrix whose columns are the eigenvectors corresponding to the k largest eigenvalues of

$$\sum_{i=1}^m \mathbf{x}_i \mathbf{x}_i^T \quad (11.3)$$

as expected. So indeed, PCA is a least squares method and it is quite sensitive to outliers.

Seoncheol Park

12 Summary

In summary, this book has no content whatsoever.

`1 + 1`

`[1] 2`

Seoncheol Park

Seoncheol Park

References

Seoncheol Park

Seoncheol Park

Bibliography

- [1] B. Hansen, *Econometrics*. Princeton University Press, 2022, p. 1080.

Seoncheol Park